Prometheus Ultra ｜普罗米修斯 • 极致

DUNYU · 盾语 · 银行 AI 智能体

# 盾语

## 银行 AI 智能体 · 仿真环境

听得懂，也守得住。

一句话办理账单、订阅、转账与长期计划

权限分级 · 策略裁决 · 条件 DAG · 全链路哈希链审计

零 Key 可演示

不连接真实银行 · 不产生真实资金

WHY • 问题

# 银行 Agent 的难点，不是多接一个模型

### 听不懂

口语、省略、错字、复合句
规则覆盖不全，硬猜会办错

### 办错账

刚还完 7,800 ，进度仍显示旧值
金额、账单、订阅必须账实一致

### 越权 / 幻觉

一句话绕过验证?
模型编造回执？必须可证伪

**盾语的答案：理解与授权分离。**

模型只负责“听懂 / 提议”，策略、确认、执行、审计由确定性代码负责。

对话主链路：消息 → 理解 → 计划 DAG → 七条校验 → 策略三级 → 确认 / 强验证 → 执行 → 事实账本 → 哈希链审计

ARCHITECTURE • 架构

# 五层架构：每一层都可替换、可审计

**交互层**

**Web / IM / 语音**

会话、确认卡、审计回放

↓

**理解层**

**规则 + 语义帧 + BGE**

可选大模型；失败回退规则

↓

**决策层**

**Planner + Validator + Policy**

条件 DAG 、七条校验、三级裁决

↓

**执行层**

**Tools + Saga + 幂等**

复式记账、逆序补偿

↓

**证据层**

**FactLedger + Audit**

事实校验、哈希链、回放

## 设计原则

01 模型输出永远不是授权

02 查询绿色直答；写操作必须确认

03 失败可回退；执行失败逆序补偿

04 每个结论都能追到事实 / 审计

仿真边界：不接真实核心

UNDERSTANDING • 理解

# 不是猜，是分层收敛

01

## 规则

高频说法直接命中

确定性、可解释

02

## 语义帧

槽位 / 时间 / 对象结构化

算金额、找收款人

03

## BGE 向量

没见过的说法做兜底

≥0.75 直接； 0.45–0.75 复述确认

04

## 澄清

<0.45 或乱码

给候选，不硬猜

**安全前置：模态 / 否定 / 第三人称，先于任何意图匹配**

“提前还款有违约金吗”不进入办理；“我不想还房贷”直接取消；“查张三的余额”拒绝并给下一步。

DAG • 条件任务

# 条件不是预计算，查询节点真实入图

**示例：查上个月账单，如果超 1000 就转 500 给张三**




n3.depends_on = [n0, n1, n2] · condition = {field: total_cents, op: >, value: 100000}

**执行规则**

条件成立 → 确认卡 → 强验证 → 按拓扑序执行
条件不成立 → 直接回答原因，不生成转账确认卡；否则分支执行 else

边界：支持支出 / 余额 + 比较 + and + else；不是任意嵌套布尔脚本。条件求值只读，不产生资金动作。

POLICY • 权限

# 三级权限：模型没有执行权

### 绿 • 只读

余额 / 流水 / 账单 / 持仓
知识咨询 / 主动提醒

**直接执行**

### 黄 • 小额办理

日累计 ⩽ 1,000 转账
新收款人 ⩽ 500 / 退订 / 调额

**确认卡：金额 / 对象 / 后果**

### 红 • 大额 / 不可逆

日累计 >1,000 转账
新收款人 >500 / 挂失 / 赎回 / 还款

**确认卡 → 强验证**

### 确认卡绑定： token • intent_id • params_hash • 过期时间 • 一次性

改金额 → E_PARAM ；改 token → E_CONFIRM_TOKEN ；执行前重新跑策略；审计链可校验。

硬上限：单笔 / 计划 50,000 元，超出直接拒绝； IM 300 元、夜间 500 元另计。

SECURITY • 安全

# 四道闸：拦截、校验、确认、审计

### 注入 / 角色伪装

前置 deny
不因一句话跳过验证

### 第三人称查询

只查本人
拒绝他人余额 / 流水 / 手机号

### 失败 Saga

逆序补偿
冻结预算原路释放

### 哈希链审计

prev_hash 串联
改一行即校验失败

评测： 448 项测试 · 243/243 评测 · 红队 58/58 · 权限边界 60/60
已公开 3 条检测漏检，执行层全部拦截，不假装 100%

EVIDENCE • 亲手验证

# 评委可以亲手把系统弄坏




## 三个按钮 • 隔离临时库

01 篡改确认 token → E_CONFIRM_TOKEN

02 篡改确认金额 → E_PARAM

03 篡改审计记录 → before=true / after=false

设置 → 安全证据，两次点击即可运行。

# 结果先行，过程可展开




## 对话原则

- 先给结果，再给执行详情
- 咨询句只答不办
- 缺槽位一次问全 / 用上次金额
- “全部展示”看完整流水
- 审计页只放决策链，不混流水

CONSISTENCY • 账实一致

# 刚还完 7,800 ，进度必须立刻变

| | | |
|---|---|---|
| 贷款进度 | 读 loans.remaining / monthly | 420,000 → 412,200 ； 23/60 → 24/60 |
| 信用卡账单 | cards.bill_cents + 本月消费 | 还款 300 后 3,280.50 → 2,980.50 |
| 可用余额 | 总余额 − 冻结 / 计划锁定 | 可用 6,945.67 （总 7,945.67 ） |
| 订阅列表 | 按 status 分组 | 在用 4 项 + 已取消 1 项 |
| 积分 | points 表 | 不再承诺兑换 |

**原则：页面上出现的每个数字，都必须能在数据库或工具结果里找到来源。**

EVIDENCE • 评测

# 数字要能复跑，不要只写在 PPT 里

| 448 | 243/243 | 58/58 | 60/60 | 27/30 |
| --- | --- | --- | --- | --- |
| 测试项 | 评测集 | 红队 | 权限边界 | 盲测 |

## 盲测 27/30，我们公开了 3 条失败

不拿盲测结果回头调规则；3 条失败保留在 docs/BLIND_TEST.md 。
已知 3 条检测绕过也公开：均未执行，靠策略兜底。

复跑： python -m unittest discover tests -q | python -m eval.runner | python -m eval.blind_runner

BOUNDARY • 边界

# 诚实，是安全的一部分

## 已经做到的

✓ 零 Key 可完整演示

✓ 条件 DAG 查询节点入图

✓ 确认卡 / 强验证 / 审计可现场验证

✓ 账实一致与失败补偿

## 仍然没做的

× 任意嵌套条件脚本

× 所有红色动作统一确认卡

× 真实人脸 /U 盾（演示为模拟）

× PPT/ 视频之外的实时录屏

**仿真环境：不连接真实银行核心，不产生真实资金；所有客户、账户、流水均为合成数据。**

**Prometheus Ultra ｜普罗米修斯 • 极致**

DUNYU · 盾语 · 银行 AI 智能体（仿真环境）

# 听得懂，也守得住。

理解与授权分离 · 条件 DAG · 策略裁决 · 哈希链审计

**现场演示入口**

双击 start.bat → http://127.0.0.1:8000 → 设置 → 安全证据 / 演示

谢谢，欢迎提问。