DUNYU · 银行 AI 智能体

盾语

银行 AI 智能体 · 仿真环境

听得懂，也守得住。

一句话办理账单、订阅、转账与长期计划
权限分级 · 策略裁决 · 条件 DAG · 全链路哈希链审计

零 Key 可演示

不连接真实银行 · 不产生真实资金

WHY • 问题

银行 Agent 的难点，不是多接一个模型

听不懂

口语、省略、错字、复合句
规则覆盖不全，硬猜会办错

办错账

刚还完 7,800 ，进度仍显示旧值
金额、账单、订阅必须账实一致

越权 / 幻觉

一句话绕过验证?
模型编造回执？必须可证伪

盾语的答案：理解与授权分离。

模型只负责“听懂 / 提议”，策略、确认、执行、审计由确定性代码负责。

对话主链路：消息 → 理解 → 计划 DAG → 七条校验 → 策略三级 → 确认 / 强验证 → 执行 → 事实账本 → 哈希链审计

ARCHITECTURE • 架构

五层架构：每一层都可替换、可审计

交互层

Web / IM / 语音

会话、确认卡、审计回放

↓

理解层

规则 + 语义帧 + BGE

可选大模型；失败回退规则

↓

决策层

Planner + Validator + Policy

条件 DAG 、七条校验、三级裁决

↓

执行层

Tools + Saga + 幂等

复式记账、逆序补偿

↓

证据层

FactLedger + Audit

事实校验、哈希链、回放

设计原则

01 模型输出永远不是授权

02 查询绿色直答；写操作必须确认

03 失败可回退；执行失败逆序补偿

04 每个结论都能追到事实 / 审计

仿真边界：不接真实核心

UNDERSTANDING • 理解

不是猜，是分层收敛

01

规则

高频说法直接命中

确定性、可解释

02

语义帧

槽位 / 时间 / 对象结构化

算金额、找收款人

03

BGE 向量

没见过的说法做兜底

≥0.75 直接； 0.45–0.75 复述确认

04

澄清

<0.45 或乱码

给候选，不硬猜

安全前置：模态 / 否定 / 第三人称，先于任何意图匹配

“提前还款有违约金吗”不进入办理；“我不想还房贷”直接取消；“查张三的余额”拒绝并给下一步。

DAG • 条件任务

条件不是预计算，查询节点真实入图

示例：查上个月账单，如果超 1000 就转 500 给张三



n3.depends_on = [n0, n1, n2] · condition = {field: total_cents, op: >, value: 100000}

执行规则

条件成立 → 确认卡 → 强验证 → 按拓扑序执行
条件不成立 → 直接回答原因，不生成转账确认卡；否则分支执行 else

边界：支持支出 / 余额 + 比较 + and + else；不是任意嵌套布尔脚本。条件求值只读，不产生资金动作。

POLICY • 权限

三级权限：模型没有执行权

绿 • 只读

余额 / 流水 / 账单 / 持仓
知识咨询 / 主动提醒

直接执行

黄 • 小额办理

≤5,000 转账 / 退订 / 调额
风险测评 / 虚拟卡

确认卡：金额 / 对象 / 后果

红 • 大额 / 不可逆

>5,000 转账 / 挂失 / 赎回
还款 / 密码重置

确认卡 → 强验证

确认卡绑定： token • intent_id • params_hash • 过期时间 • 一次性

改金额 → E_PARAM ；改 token → E_CONFIRM_TOKEN ；执行前重新跑策略；审计链可校验。

SECURITY • 安全

四道闸：拦截、校验、确认、审计

注入 / 角色伪装

前置 deny
不因一句话跳过验证

第三人称查询

只查本人
拒绝他人余额 / 流水 / 手机号

失败 Saga

逆序补偿
冻结预算原路释放

哈希链审计

prev_hash 串联
改一行即校验失败

评测： 448 项测试 · 243/243 评测 · 红队 58/58 · 权限边界 60/60
已公开 3 条检测漏检，执行层全部拦截，不假装 100%

EVIDENCE • 亲手验证

评委可以亲手把系统弄坏



三个按钮 • 隔离临时库

01 篡改确认 token → E_CONFIRM_TOKEN

02 篡改确认金额 → E_PARAM

03 篡改审计记录 → before=true / after=false

设置 → 安全证据，两次点击即可运行。

结果先行，过程可展开



对话原则

- 先给结果，再给执行详情
- 咨询句只答不办
- 缺槽位一次问全 / 用上次金额
- “全部展示”看完整流水
- 审计页只放决策链，不混流水

CONSISTENCY • 账实一致

刚还完 7,800 ，进度必须立刻变

贷款进度	读 loans.remaining / monthly	420,000 → 412,200 ； 23/60 → 24/60
信用卡账单	cards.bill_cents + 本月消费	还款 300 后 3,280.50 → 2,980.50
可用余额	总余额 − 冻结 / 计划锁定	可用 6,945.67 （总 7,945.67 ）
订阅列表	按 status 分组	在用 4 项 + 已取消 1 项
积分	points 表	不再承诺兑换

原则：页面上出现的每个数字，都必须能在数据库或工具结果里找到来源。

EVIDENCE • 评测

数字要能复跑，不要只写在 PPT 里

448	243/243	58/58	60/60	27/30
测试项	评测集	红队	权限边界	盲测

盲测 27/30，我们公开了 3 条失败

不拿盲测结果回头调规则；3 条失败保留在 docs/BLIND_TEST.md 。
已知 3 条检测绕过也公开：均未执行，靠策略兜底。

复跑： python -m unittest discover tests -q | python -m eval.runner | python -m eval.blind_runner

BOUNDARY • 边界

诚实，是安全的一部分

已经做到的

✓ 零 Key 可完整演示

✓ 条件 DAG 查询节点入图

✓ 确认卡 / 强验证 / 审计可现场验证

✓ 账实一致与失败补偿

仍然没做的

× 任意嵌套条件脚本

× 所有红色动作统一确认卡

× 真实人脸 /U 盾（演示为模拟）

× PPT/ 视频之外的实时录屏

仿真环境：不连接真实银行核心，不产生真实资金；所有客户、账户、流水均为合成数据。

DUNYU · 银行 AI 智能体（仿真环境）

听得懂，也守得住。

理解与授权分离 · 条件 DAG · 策略裁决 · 哈希链审计

现场演示入口

双击 start.bat → http://127.0.0.1:8000 → 设置 → 安全证据 / 演示

谢谢，欢迎提问。